

Report

Pattern Recognition Assignment 2: Activity Classification Challenge



제출일 2024.12.18

과목명 패턴인식

전공 모바일시스템공학과

학번 32204012

이름 전해림

목차

1. Introduction

- 1) 과제의 목적, 개요

2. Dataset Overviews

- 1) analysis of the HAR dataset

3. Experiment and Results

- 1) activity_train.ipynb - CNN model
- 2) activity_train.ipynb - BiLSTM model
- 3) activity_test.ipynb
- 4) The rational behind choosing specific feature extraction methods and models
- 5) How you selected the model parameters
- 6) The techniques you used to optimize your models

4. Conclusion

- 1) model selection
 - The criteria and reasoning for selecting one of the two systems as your final submission.
- 2) conclusion

1. Introduction (Background)

현대 사회에서 스마트폰은 단순한 통신 도구를 넘어 다양한 분야에서 혁신적인 변화를 이끌고 있는 핵심 기술로 자리 잡았습니다. 특히, 스마트폰에 내장된 가속도계(accelerometer)와 자이로스코프(gyroscope) 같은 센서들은 사용자의 물리적 활동을 측정하고 분석할 수 있는 강력한 도구로 활용되고 있습니다. 이러한 센서 데이터를 분석하면 걷기, 달리기, 계단 오르기와 같은 일상적인 활동뿐만 아니라 앉기, 서기, 눕기 등 자세 변화를 포함한 다양한 움직임을 감지할 수 있습니다. 이 기술은 스마트 헬스케어 기기, 그리고 스마트홈 애플리케이션과 같이 실생활에 다양하게 적용되고 있습니다.

이번 프로젝트는 스마트폰 센서를 통해 수집된 데이터를 기반으로 사용자의 활동을 분류하는 시스템을 개발하는 데 초점을 맞추고 있습니다. 제공된 데이터는 사용자의 가속도와 각속도를 포함한 6개의 센서 값으로 구성되어 있으며, 128개의 시간 샘플로 나타나는 창(window) 형태로 저장되어 있습니다. 이러한 데이터는 스마트폰의 센서를 통해 초당 50Hz로 수집되었으며, 각 파일은 사용자의 특정 활동에 해당하는 label(1~6)과 함께 제공됩니다.

과제는 원시 센서 데이터를 분석하여 특징(feature)을 추출하고, 이를 머신러닝 모델에 적합하게 변환하여 높은 정확도로 6가지 활동을 분류할 수 있는 효과적인 시스템을 설계하는 것입니다.

2.Dataset overviews

2.1) HAR dataset

HAR 데이터는 스마트폰 센서를 통해 수집된 원시 데이터를 포함하고 있으며, 각 파일은 128×6 크기의 매트릭스로 구성되어 있습니다. 이 매트릭스는 2.56초 동안 수집된 50Hz 샘플 데이터를 나타내며, 총 6개의 열(column)로 구성되어 있습니다. 각 열은 다음과 같은 센서 데이터를 포함합니다:

1. 가속도(X, Y, Z 축): 표준 중력 단위($g = 9.8 \text{ m/s}^2$)로 표현되며, 사용자의 움직임에 따른 가속도를 측정합니다.
2. 각속도(X, Y, Z 축): 초당 라디안(rad/s) 단위로 표현되며, 사용자의 회전 동작을 나타냅니다.

각 행(row)은 특정 시간 샘플에서의 센서 데이터를 나타내며, 이러한 구조는 시간-공간적 관계를 유지하면서 사용자의 활동에 대한 상세한 정보를 제공합니다. 데이터의 해상도(128 샘플)는 활동 분류를 위한 충분한 정보를 포함하면서도 계산 효율성을 고려한 적절한 수준으로 설계되었습니다.

데이터셋은 여러 개의 텍스트 파일로 제공되며, 파일명은 다음과 같은 규칙을 따릅니다:

형식: `aaaa_bb_c.txt`

- `aaaa`: 파일 ID (고유 식별자)
- `bb`: 사용자 ID (데이터 수집에 참여한 사용자 식별자)
- `c`: 활동 클래스 (1~6)

활동 클래스는 다음과 같이 정의됩니다:

1. 걷기(Walking)
2. 계단 오르기(Walking Upstairs)
3. 계단 내리기(Walking Downstairs)
4. 앉기(Sitting)
5. 서기(Standing)
6. 눕기(Laying)

스마트폰 센서 데이터는 원시 데이터(raw data) 형태로 제공되기 때문에, 분류 모델에 적합하도록 전처리 과정이 필수적입니다. 전처리는 데이터의 품질을 향상시키고, 모델의 학습 및 예측 성능을 최적화하는 데 중요한 역할을 합니다. 적절한 데이터 정규화와 특징 추출 과정을 통해, 원시 데이터의 복잡성을 줄이고 분류 모델의 학습 효율성을 높일 수 있을 것입니다.

1. 데이터 정규화

- 센서 데이터의 범위와 단위(가속도는 g 단위, 각속도는 rad/s 단위)는 서로 다르기 때문에, 데이터 정규화를 통해 범위를 조정해야 합니다. 이를 통해 모델 학습 과정에서 특정 특징의 중요도가 과도하게 높아지는 것을 방지할 수 있습니다.
- 표준화(Standardization)를 적용하여 모든 특징이 평균 0, 표준편차 1의 분포를 가지도록 처리합니다.

2. 특징 추출

- 원시 데이터는 시계열 정보로 구성되어 있으나, 머신러닝 모델은 고정된 크기의 벡터 형태 데이터를 필요로 합니다. 따라서, 시간 도메인(평균, 표준편차 등)과 주파수 도메인(FFT

기반 특징 등)에서 유의미한 특징을 추출하여 입력 데이터로 변환해야 합니다.

- 이러한 과정은 모델이 센서 데이터에서 활동의 고유한 패턴을 학습하는 데 도움을 줍니다.

3. 노이즈 제거:

- 센서 데이터는 종종 환경적 요인에 의해 노이즈가 포함될 수 있습니다. 이러한 노이즈를 제거하거나 완화하지 않으면 모델의 성능에 부정적인 영향을 미칠 수 있으므로, 특징 추출 과정에서 RMS(Root Mean Square)와 같은 기술을 활용해 노이즈 영향을 줄입니다.

3. Experiment and Results

3.1) activity_train.ipynb – CNN

CNN 모델은 입력 데이터를 처리하기 위해 Conv1D 계층을 사용했습니다. 첫 번째 Conv1D 계층은 128개의 필터와 커널 크기 3을 사용하여 시계열 데이터의 지역적 패턴을 추출했습니다. 이 계층은 주어진 시간 창 내의 주요 특징을 감지하며, 데이터의 공간적 구조를 학습할 수 있도록 설계되었습니다. Conv1D 계층을 사용하는 이유는 시간 데이터에서 국소적인 특징을 효율적으로 학습할 수 있기 때문입니다.

MaxPooling1D 계층은 Conv1D 계층 뒤에 배치되어 데이터의 차원을 줄이고, 특징 추출 과정에서 발생할 수 있는 과적합 문제를 완화합니다. 이 계층은 가장 중요한 특징만을 강조하며, 학습 과정을 단순화하는 데 도움을 줍니다. 이 과정을 통해 모델은 입력 데이터를 보다 압축된 형태로 표현할 수 있습니다.

Flatten 계층은 다차원 특징 맵을 1D 벡터로 변환하여 Dense 계층에 입력할 수 있도록 합니다. 이는 최종 분류를 수행하기 전에 특징을 완전 연결 계층으로 전달하기 위해 필요합니다. Dense 계층에서는 256개의 뉴런과 ReLU 활성화 함수를 사용하여 비선형성을 추가하고, 복잡한 패턴을 학습할 수 있도록 합니다. ReLU 활성화 함수는 계산 비용이 낮으면서도 학습 속도를 높이는 데 기여합니다.

마지막으로, Softmax 활성화 함수를 사용하는 출력 계층에서는 활동 클래스의 확률 분포를 생성합니다. 이 계층은 각 클래스에 대한 예측 확률을 반환하며, 가장 높은 확률을 가진 클래스를 최종 분류 결과로 선택합니다. Softmax는 다중 클래스 분류 문제에서 필수적인 출력 방식입니다.

모델의 최적화 과정에서는 Adam 옵티마이저를 사용했으며, 학습률은 0.001로

설정했습니다. Adam 옵티마이저는 학습 속도를 높이고 안정적인 수렴을 보장하는 데 적합합니다. 다중 클래스 분류 문제를 해결하기 위해 Categorical Crossentropy 손실 함수를 사용했으며, Early Stopping과 학습률 감소 콜백을 적용하여 검증 손실이 개선되지 않으면 학습을 중단하거나 학습률을 동적으로 조정했습니다.

CNN 모델은 시계열 데이터를 처리하는 데 적합하며, 지역적인 특징을 효과적으로 학습할 수 있는 장점을 가지고 있습니다. 이러한 설계는 입력 데이터의 시간적 구조를 최적화하며, 계산 효율성을 유지하면서도 높은 성능을 달성할 수 있도록 했습니다. 모델 학습 과정에서 클래스 불균형 문제를 해결하기 위해 균형 잡힌 배치를 구성했으며, 드롭아웃 계층을 활용하여 과적합 문제를 완화했습니다. 결과적으로 CNN 모델은 활동 분류 문제에서 87.88%의 높은 성능을 보였으며, 데이터의 특징을 효과적으로 학습했습니다. BiLSTM 모델과 비교했을 때, CNN은 계산 효율성이 높은 장점을 제공하며 단순한 구조로도 높은 정확도를 달성했습니다.

3.2) activity_train.ipynb – BiLSTM

BiLSTM 네트워크는 순차 데이터를 처리하는 데 매우 적합하며, 과거와 미래의 맥락을 동시에 고려하여 예측의 정밀도를 높일 수 있습니다. 본 모델은 입력 계층에서 128x6 크기의 시퀀스를 처리하며, 첫 번째 BiLSTM 계층에서는 256개의 뉴런과 `return_sequences=True` 설정을 사용하여 양방향 시간 패턴을 학습했습니다. 이후 드롭아웃 계층과 배치 정규화를 적용하여 학습 안정성을 높이고 과적합을 방지했습니다. 두 번째 BiLSTM 계층에서는 128개의 뉴런을 사용하여 추가적으로 특징을 정제했습니다. 마지막으로 Dense 계층에서는 256개의 뉴런과 ReLU 활성화 함수를 적용하여 비선형성과 밀집 연결을 제공하며, 출력 계층에서는 Softmax 함수를 통해 활동 클래스 확률을 예측했습니다.

모델의 최적화 과정에서 Adam 옵티마이저를 사용했으며, 학습률은 0.001로 설정했습니다. 다중 클래스 분류 문제를 해결하기 위해 Categorical Crossentropy 손실 함수를 사용했으며, Early Stopping과 학습률 감소 콜백을 적용하여 검증 손실이 개선되지 않으면 학습을 중단하거나 학습률을 동적으로 조정했습니다. 다른 대안 모델로 CNN과 단순 LSTM을 고려했으나, BiLSTM이 양방향 시간 의존성을 활용하여 정확도 면에서 더 나은 성능을 보여 선택되었습니다.

모델 학습 과정에서 클래스 불균형 문제를 해결하기 위해 균형 잡힌 배치를 구성했으며, 드롭아웃 계층과 Early Stopping을 통해 과적합 문제를 완화했습니다.

결과적으로 BiLSTM 모델은 활동 분류 문제에서 82.93%의 성능을 보였습니다.

3.3) activity_test.ipynb

테스트 모듈은 activity_train.ipynb에서 훈련된 모델을 활용하여 주어진 테스트 데이터를 기반으로 활동 클래스를 예측하는 데 초점을 맞추고 있습니다. 이 과정은 모델의 일반화 성능을 검증하고, 실제 활용 가능성을 평가하는 중요한 단계입니다.

테스트 데이터는 128×6 형태의 매트릭스로 제공되었으며, 레이블 정보는 포함되어 있지 않았습니다. 이는 모델이 순수히 입력 데이터에 기반해 활동 클래스를 예측해야 함을 의미합니다. 각 데이터 파일은 독립적으로 처리되어야 하며, 이름 형식은 aaaa.txt로 지정되었습니다. 따라서 테스트 모듈은 파일별로 개별적인 예측 결과를 생성하도록 설계되었습니다.

테스트 과정은 두 단계로 진행되었습니다. 첫 번째 단계는 훈련된 모델을 로드하고 테스트 데이터를 전처리하는 것입니다. activity_train.ipynb에서 저장된 모델 파일은 Keras의 load_model 함수를 사용해 불러왔습니다. 이때 모델 구조와 가중치가 함께 로드되었습니다. 이후, 테스트 데이터에는 훈련 데이터와 동일한 전처리 과정이 적용되었습니다. 데이터는 평균 0, 분산 1로 정규화되었고, 길이가 128로 고정된 시퀀스 형태로 변환되었습니다. 이러한 전처리는 훈련 데이터와의 일관성을 유지하고 모델 예측의 신뢰성을 높이기 위해 필수적이었습니다.

두 번째 단계는 모델을 이용한 예측과 결과 저장입니다. 테스트 데이터 파일은 하나씩 로드되어 모델에 입력되었고, 모델은 각 클래스의 확률값을 출력했습니다. 가장 높은 확률값을 가진 클래스가 최종 예측으로 선택되었습니다. 예측 결과는 result_id_name.txt 형식의 텍스트 파일로 저장되었습니다.

```
Mounted at /content/drive
93/93  2s 6ms/step
Classification results saved to /content/drive/MyDrive/Pattern_recognition_Assignment2/result_32204012-HyelimJeon.txt.
```

```
result_32204012_HyelimJeon.txt
0000.txt: 1
0001.txt: 1
0002.txt: 1
0003.txt: 1
0004.txt: 1
0005.txt: 1
0006.txt: 1
0007.txt: 1
0008.txt: 1
0009.txt: 1
0010.txt: 1
0011.txt: 1
0012.txt: 1
0013.txt: 1
0014.txt: 1
0015.txt: 1
0016.txt: 1
0017.txt: 1
0018.txt: 1
0019.txt: 1
0020.txt: 1
0021.txt: 1
0022.txt: 1
0023.txt: 1
0024.txt: 1
0025.txt: 1
0026.txt: 1
0027.txt: 1
0028.txt: 1
0029.txt: 1
```

3.4) The rational behind choosing specific feature extraction methods and models

활동 분류 시스템의 성능을 극대화하기 위해 스마트폰 센서 데이터에서 시간 및 주파수 도메인의 다양한 특징을 추출하였습니다. 특징 추출은 원시 데이터에서 중요한 정보를 효과적으로 추출하여 모델이 학습 가능한 형태로 변환하는 핵심 단계로, 데이터의 특성을 분석하여 가장 적합한 접근 방식을 설계하였습니다. 시간 도메인 특징과 주파수 도메인 특징의 추출 방법과 그 근거를 상세히 설명하고, 이 두 가지 특징의 결합을 통해 최종적으로 생성된 입력 데이터의 구조를 제시하겠습니다.

시간 도메인 특징은 원시 데이터를 기반으로 직접 계산되며, 각 활동 클래스의 기본적인 통계적 속성을 나타냅니다. 추출된 주요 시간 도메인 특징은 다음과 같습니다:

- 평균값(Mean): 신호의 중심값으로, 활동 간 전반적인 차이를 파악하는 데 유용합니다. 예를 들어, 앉기와 계단 오르기의 평균값은 크게 다릅니다.
- 표준편차(Standard Deviation): 신호의 변동성을 나타내며, 동적 활동(예: 걷기)과 정적 활동(예: 앉기)을 구별하는 데 효과적입니다.

- 최소값(Min)과 최대값(Max): 신호의 진폭 범위를 나타내며, 활동의 강도와 세기를 분석할 수 있습니다.
 - 중앙값(Median): 데이터의 중간값으로, 이상치(outlier)에 강건한 특징입니다.
 - 절대 평균값(Absolute Mean): 신호의 절대값의 평균으로, 활동의 전반적인 크기를 강조합니다.
 - 왜도(Skewness): 신호 분포의 비대칭성을 나타내며, 독특한 활동 패턴을 식별하는 데 유용합니다.
 - 첨도(Kurtosis): 신호 분포의 첨도를 측정하여 활동 간의 신호 분포 차이를 파악합니다.
 - 신호 크기 합(Signal Magnitude Area, SMA): 모든 축에서 신호의 총 크기를 합산하여 활동의 강도를 표현합니다.
- 시간 도메인 특징은 데이터의 통계적 성질을 설명하며, 동적 활동과 정적 활동 간 차이를 강조하는 데 유용했습니다.

주파수 도메인 특징은 신호의 주파수 성분을 분석하여 시간 도메인에서 파악하기 어려운 정보를 제공합니다. 본 프로젝트에서는 FFT(Fast Fourier Transform)를 활용해 신호를 시간 도메인에서 주파수 도메인으로 변환하였으며, 다음과 같은 특징을 추출하였습니다:

- FFT 크기(FFT Magnitude): 주파수 성분의 절대값으로, 신호의 에너지 분포를 나타냅니다.
- FFT 평균값 및 표준편차: 주파수 스펙트럼의 중심값과 변동성을 분석하여 활동의 주파수 성향을 학습할 수 있도록 합니다.
- 상위 N개의 주파수 성분(Top N Frequencies): 에너지가 가장 높은 상위 5개의 주파수 성분을 추출하여 주요 패턴을 학습하도록 합니다.
- 주파수 중심(Frequency Centroid): 주파수 분포의 무게 중심으로, 활동 간 주파수 특성의 차이를 반영합니다.
- 주파수 엔트로피(Frequency Entropy): 주파수 분포의 불확실성을 측정하여 복잡한 활동 간 차이를 분석하는 데 유용합니다.
- 파워 스펙트럼(Power Spectrum): 신호의 총 에너지를 계산하여 활동의 강도를 측정합니다.

주파수 도메인 특징은 특히 동적 활동(예: 걷기, 계단 오르기)에서 신호의 주파수 특성을 강조하여 더 명확한 패턴을 제공하였습니다.

시간 도메인과 주파수 도메인 특징은 서로 다른 정보를 제공하므로, 두 가지 특징을

결합하여 풍부한 입력 데이터를 생성하였습니다. np.hstack 함수를 사용하여 시간 도메인 특징과 주파수 도메인 특징을 하나의 벡터로 통합하였으며, 이를 통해 모델이 시간적 및 주파수적 패턴을 동시에 학습할 수 있도록 하였습니다.

3.5) How you selected the model parameters

모델의 손실 함수로는 다중 클래스 분류에 적합한 Categorical Crossentropy를 사용하였으며, 옵티마이저로는 학습 속도와 안정성을 제공하는 Adam을 선택하였습니다. 초기 학습률은 0.001로 설정되었으며, 학습 중 검증 손실이 개선되지 않을 경우 ReduceLROnPlateau를 통해 학습률을 동적으로 조정하여 안정적인 수렴을 유도하였습니다. 또한, 학습 과정에서 과적합을 방지하기 위해 Early Stopping을 적용하여 검증 손실이 10 에폭 동안 개선되지 않으면 학습을 중단하도록 하였습니다. 배치 크기는 32로 설정하여 적절한 계산 효율성을 유지하면서도 충분한 데이터를 학습할 수 있도록 하였습니다.

CNN 모델에서는 시계열 데이터의 국소적인 패턴을 학습하기 위해 두 개의 Conv1D 레이어를 사용하였습니다. 첫 번째 Conv1D 레이어는 64개의 필터와 커널 크기 3으로 구성되었으며, 두 번째 Conv1D 레이어는 128개의 필터를 사용하여 더 깊은 특징을 학습하도록 설계되었습니다. 각 Conv1D 레이어 뒤에는 MaxPooling1D 레이어를 추가하여 특성 맵의 크기를 줄이고 계산 효율성을 높였습니다. 드롭아웃 비율은 0.4로 설정하여 과적합을 방지하였고, 마지막 완전 연결(Dense) 레이어는 256개의 뉴런으로 구성되어 고차원 특징을 학습할 수 있도록 설계되었습니다.

BiLSTM 모델은 시계열 데이터의 양방향 시간적 의존성을 학습하기 위해 설계되었습니다. 첫 번째 BiLSTM 레이어는 256개의 유닛으로 주요 패턴을 학습하도록 하였으며, 두 번째 BiLSTM 레이어는 128개의 유닛으로 더 세밀한 특징을 학습할 수 있도록 구성되었습니다. 각 BiLSTM 레이어 뒤에는 드롭아웃(0.4)과 배치 정규화를 적용하여 과적합을 방지하고 학습 안정성을 높였습니다. 마지막 Dense 레이어는 256개의 뉴런과 ReLU 활성화 함수를 사용하였으며, 최종 출력 레이어는 Softmax 활성화 함수를 통해 클래스별 확률을 예측하도록 설계되었습니다.

모델 파라미터는 데이터 특성과 계산 효율성을 고려하여 실험적으로 조정되었습니다. 특히, CNN은 국소적인 특징 학습에, BiLSTM은 시간적 의존성 학습에 강점을 가지고 있어 각각의 모델 구조를 데이터 특성에 맞게 설계하였습니다. 이러한 체계적인 파라미터 설정과 최적화 전략은 모델의 학습 효율성과 분류 성능을 극대화하는 데 기여하였으며, 높은 정확도의 활동 분류 모델을 구축하는 데 중요한 역할을 하였습니다.

3.6) The techniques you used to optimize your models

우선, 학습률 조정을 위해 ReduceLROnPlateau 콜백을 사용하였습니다. 학습 과정에서 검증 손실이 개선되지 않을 경우 학습률을 동적으로 줄여, 초기에는 빠르게 손실을 감소시키고 후반부에는 안정적으로 수렴하도록 하였습니다. 이를 통해 학습률이 너무 크거나 작아 발생할 수 있는 학습 불안정을 방지할 수 있었습니다.

또한, 과적합을 방지하기 위해 Early Stopping 기법을 활용하였습니다. 검증 손실이 10 에폭 동안 개선되지 않으면 학습을 중단하도록 설정하여, 불필요한 학습 시간을 줄이고 최적의 모델을 확보할 수 있었습니다. 이와 함께 드롭아웃(Dropout)을 CNN과 BiLSTM 모델에 적용하여 뉴런의 출력을 일부 무작위로 제거하였습니다. CNN 모델에서는 드롭아웃 비율을 0.4로 설정하였고, BiLSTM 모델에서도 각 LSTM 계층 뒤에 동일한 비율로 적용하여 과적합을 효과적으로 억제하였습니다.

BiLSTM 모델의 학습 안정성을 높이기 위해 배치 정규화(Batch Normalization)도 활용하였습니다. 배치 정규화는 각 레이어의 입력 분포를 정규화하여 학습 과정에서의 불안정성을 줄이고, 빠른 수렴을 유도하는 데 기여하였습니다. 이 외에도, 모델 입력 데이터를 정규화(Standard Scaling)하여 평균이 0, 분산이 1이 되도록 조정하였습니다. 이는 모델이 입력 값의 스케일 차이에 영향을 받지 않고 학습할 수 있도록 돕는 중요한 과정이었습니다.

입력 데이터의 차원을 축소하기 위해 PCA(Principal Component Analysis)를 적용하였습니다. 이는 주요 정보를 보존하면서 데이터의 계산 복잡도를 줄이고, 모델의 학습 속도를 높이는 데 기여하였습니다. 이와 같은 차원 축소는 특히 고차원 데이터를 처리하는 BiLSTM 모델에서 효과적이었습니다.

CNN 모델에서는 Conv1D와 MaxPooling1D 레이어를 적절히 조합하여 국소적 특징을 학습하였고, Flatten 레이어와 Dense 레이어를 통해 고차원 데이터를 처리할 수 있도록 설계하였습니다. BiLSTM 모델은 양방향 시간적 의존성을 학습할 수 있도록 구성되었으며, 드롭아웃과 배치 정규화를 추가하여 학습의 안정성을 보장하고, Dense 레이어에서 세밀한 특징을 학습할 수 있었습니다.

마지막으로, 배치 크기는 32로 설정하여 A100 GPU 메모리를 활용하였으며, 최대 에폭은 50으로 설정하여 충분한 학습을 보장하였습니다. 이러한 설정은 Early Stopping과 함께 사용되어 학습의 효율성을 더욱 높였습니다.

위의 최적화 기술을 통해 모델의 학습 속도와 안정성을 높이고, 과적합을 방지하며 높은 정확도의 활동 분류 모델을 구축할 수 있었습니다. 이러한 기술은 모델의 성능 향상뿐만 아니라 학습 과정의 효율성까지 보장하는 데 중요한 역할을 하였습니다.

4. Conclusion

4.1) Model Selection: The criteria and reasoning for selecting one of the two systems as your final submission

```
-----| Ensemble Results |-----
Ensemble Accuracy: 85.40%

-----| Final Result |-----
CNN Accuracy      : 87.88%
BiLSTM Accuracy   : 82.93%

CNN model is superior. Selected as the final model.
Final Accuracy    : 87.88%

CNN model saved at /content/drive/MyDrive/Pattern_recognition_Assignment2/models3/cnn_model.keras.
```

최종적으로 정확도가 87.88%로 가장 높게 나온 CNN model을 선택하였습니다.

4.2) Conclusion

본 프로젝트는 스마트폰 센서를 활용한 활동 분류 시스템 설계를 목표로, CNN과 BiLSTM 두 모델을 개발하고 비교 분석하여 최적의 결과를 도출하였습니다. 데이터의 특성을 철저히 분석하여 정규화, 원핫 인코딩, 클래스 가중치 설정 등의 효과적인 전처리 방법을 적용했으며, 이를 통해 모델 학습의 안정성과 정확도를 향상시켰습니다. 또한, 다양한 하이퍼파라미터 튜닝과 최적화 기법을 적용하여 모델의 성능을 극대화하였습니다.

최종적으로 CNN 모델이 뛰어난 정확도와 효율성을 보여 최종 제출 모델로 선정하였습니다. 본 프로젝트는 데이터의 구조적 특성과 문제의 요구사항을 균형 있게 반영한 설계와 검증 과정을 통해 실용적이고 강력한 분류 시스템을 구현하였습니다. 과제를 마치며, 향후에는 다중 회귀 분석 및 교차 검증을 포함한 다양한 평가 방법을 추가하여 모델 성능을 보다 심층적으로 분석하고 싶다는 생각이 들었습니다. 특히, 추가 특성을 고려한 다변수 회귀 분석과 비선형 모델링 기법을 도입하여 실제 더 복잡한 데이터를 정확하게 예측할 수 있는 모델을 개발할 수 있을 것이라 생각합니다.

과제를 수행하면서 수학적 원리를 직접 적용하고, 다양한 회귀 기법의 장단점을 비교하는 과정을 통해 패턴인식 과목에 대한 이해도가 한층 높아졌다고 느낍니다.

앞으로도 지속적인 학습과 실험을 통해 이론적 지식을 실제 문제에 적용할 수 있는 능력을 키워나가고 싶습니다.